

Projet 7 — Détection d'anomalies dans les transactions financières

Étude comparative des méthodes de détection de fraude avec PySpark

1. Introduction

La détection de fraude sur les transactions financières est un problème critique dans le secteur bancaire. Les systèmes modernes doivent être capables d'identifier des comportements anormaux en temps réel afin de limiter les pertes financières et protéger les clients.

Ce projet vise à analyser un jeu de données de transactions de cartes de crédit fortement déséquilibré et à comparer plusieurs approches de machine learning pour la détection d'anomalies :

- Isolation Forest (non supervisé)
- K-Means clustering (non supervisé)
- Classification supervisée (Logistic Regression)

L'objectif est d'évaluer les performances de chaque méthode en tenant compte du déséquilibre des classes et de l'impact métier des erreurs.

2. Jeu de données et déséquilibre des classes

Le dataset contient des transactions financières étiquetées comme :

- 0 : transaction normale
- 1 : transaction frauduleuse

Distribution des classes :

- Transactions normales : 154 283 (99.78%)
- Transactions frauduleuses : 338 (0.22%)

Ce déséquilibre extrême rend l'apprentissage difficile, car un modèle naïf pourrait obtenir une haute accuracy en prédisant uniquement la classe majoritaire.

👉 Conclusion : les métriques comme l'accuracy ne sont pas pertinentes. On privilégie le rappel, la précision et l'AUC-ROC.

3. Prétraitement des données

Les étapes suivantes ont été réalisées avec PySpark ML :

- Assemblage des variables en un vecteur unique (VectorAssembler)
- Normalisation des features avec StandardScaler

Résultat :

- Colonne finale : `scaledFeatures`
- Variable cible : `Class`

La normalisation est essentielle pour les algorithmes basés sur les distances et les gradients.

4. Méthodes de détection d'anomalies

4.1 Isolation Forest (non supervisé)

L'Isolation Forest a été appliqué afin de détecter les anomalies sans utiliser les labels.

Résultats :

- Fraude détectée correctement (TP) : 128
- Fraude non détectée (FN) : 210
- Faux positifs : 182

Interprétation :

- Recall $\approx 38\%$
- Méthode capable de détecter des anomalies inconnues
- Mais insuffisante pour un système de fraude bancaire critique

👉 Limitation : faible rappel.

4.2 K-Means Clustering

Le modèle K-Means ($k=2$) a été utilisé pour regrouper les transactions.

Analyse des clusters :

- Cluster 0 : taux de fraude $\approx 0.58\%$
- Cluster 1 : taux de fraude $\approx 0.08\%$

Interprétation :

- Les fraudes sont légèrement regroupées dans un cluster spécifique
- Mais forte superposition entre classes normales et frauduleuses

👉 Conclusion : clustering insuffisant pour détection fiable.

5. Classification supervisée : Logistic Regression

Une régression logistique a été entraînée avec gestion du déséquilibre via pondération des classes.

Gestion du déséquilibre :

- Ratio calculé : 456.46
- Pondération plus élevée pour la classe frauduleuse

6. Résultats du modèle supervisé

Métriques obtenues :

- AUC-ROC : 0.9576
- Précision : 0.9997
- Rappel : 0.9838
- F1-score : 0.9899

Matrice de confusion :

- Vrais positifs (fraude détectée) : 58
- Faux négatifs (fraude manquée) : 10
- Faux positifs : 503
- Vrais négatifs : 30 456

7. Analyse des erreurs et impact métier

Faux négatifs (FN)

- Fraudes non détectées : 10
- Impact : perte financière directe
 - 👉 C'est l'erreur la plus critique

Faux positifs (FP)

- Transactions normales bloquées : 503
- Impact : gêne utilisateur
 - 👉 Acceptable dans un système bancaire

Conclusion métier :

Dans la détection de fraude, il est préférable de minimiser les faux négatifs même si cela augmente légèrement les faux positifs.

8. Stratégie de seuil

Le seuil de classification standard (0.5) peut être ajusté pour améliorer la détection :

- Diminuer le seuil → augmente le rappel
- Augmenter le seuil → augmente la précision

Dans ce projet, un seuil plus bas est préférable afin de détecter davantage de fraudes.

9. Comparaison des méthodes

Méthode	Type	Performance	Avantages	Limites
Isolation Forest	Non supervisé	Moyen	Détecte anomalies inconnues	Faible recall
K-Means	Non supervisé	Faible	Simple et rapide	Mauvaise séparation
Logistic Regression	Supervisé	Excellent	Haute précision et recall	Besoin de labels

10. Conclusion

Ce projet a permis de comparer différentes approches de détection d'anomalies dans un contexte de fraude bancaire fortement déséquilibré.

Conclusions principales :

- Les méthodes non supervisées (Isolation Forest, K-Means) sont utiles pour explorer les données mais insuffisantes pour la production.
- La régression logistique avec gestion du déséquilibre offre les meilleures performances.
- Le rappel est la métrique la plus importante dans un système de fraude.

Modèle recommandé :

👉 Logistic Regression pondérée

11. Recommandations

- Utiliser un modèle supervisé en production
- Maintenir un système hybride (supervisé + détection d'anomalies)
- Ajuster dynamiquement le seuil selon les coûts métier
- Surveiller en continu les faux négatifs